

FACULTAD DE CIENCIAS

Modelos de Supervivencia y Series de Tiempo

Tarea Práctica 5

Anthonie Byron Ornelas Clement

10 de noviembre de 2026

Introducción

La empresa que nos contrató opera una tienda en línea y quiere saber qué modificación a su producto mejoraría la rentabilidad. El análisis de la información recolectada en el último año (1,000 clientes) arroja un hallazgo incómodo pero accionable: **ningún rasgo observable del cliente anticipa su fuga** — edad, ingreso, gasto, devoluciones, soporte, satisfacción y respuesta a promociones discriminan igual entre quienes abandonan y quienes no. El riesgo es de **52.6 % en el año, presente todo el año con aceleración al final** (según la curva de Kaplan–Meier, la mitad de la base habría fugado hacia el día 269).

La consecuencia directa para el negocio: esperar señales para retener no funciona con estos datos, así que la acción recomendada es un **ciclo de re-engagement universal y calendario fijo** (contacto preventivo antes del día 180, cuando la permanencia aún es del 70.4 %), más una **re-instrumentación del registro de clientes** para que el siguiente análisis sí pueda detectar segmentos de riesgo.

Planteamiento del problema y propuesta

La tienda vende en línea a clientes cuya actividad se mide por compras; el producto incluye promociones, atención a soporte y comunicación por correo. La dirección pregunta qué cambiar en el producto para retener más clientes: cada punto de retención preserva el ingreso que el cliente genera sin costo de adquisición.

En lugar de clasificar clientes como "fugados o no" al final del año, usamos **análisis de supervivencia**, que estudia *cuánto tarda en ocurrir un evento*. Aquí el evento es la fuga (el cliente marcado como abandonado) y el tiempo es la inactividad: los días transcurridos desde su última compra. Esta técnica aporta dos ventajas directas para decidir: entrega una **línea de tiempo del riesgo** (en qué días conviene actuar) y **compara grupos** (¿retiene más quien responde promociones?). Un cliente que no ha fugado al cierre del análisis simplemente aporta la información de que sobrevivió hasta su último registro (censura); no se le descarta.

Las preguntas que organiza el análisis:

1. ¿En qué momento del año se concentra la fuga? (timing de la acción.)
2. ¿Algún segmento de clientes fuga más rápido que otro? (¿a quién apuntar?)
3. ¿Las promociones y el soporte están asociados con la retención? (¿qué modificar del producto?)

La base y su limpieza

La base tiene 1,000 clientes y 15 variables (identificador, perfil demográfico y económico, comportamiento de compra y abandono). La inspección y las decisiones se resumen en la Tabla 1; **no se eliminó ningún cliente** y ninguna variable requirió imputación o truncado: no hay duplicados, no hay perdidos y ninguna de las 10 variables numéricas tiene observaciones fuera de 1.5 rangos intercuartílicos (suma de extremos detectados: 0; Figura 2).

La construcción del **par de supervivencia** merece nota explícita: el *evento* es `Target_Churn` (1 = fugado) y el *tiempo* es `Last_Purchase_Days_Ago` (inactividad al cierre del año). Los clientes sin fuga quedan **censurados**: sabemos que seguían activos hasta su última compra, entre los días 1 y 364 del año, pero no su vida completa. La limitación que esto impone — la fuga se mide contra la última compra y no contra una fecha de baja declarada — se retoma en las conclusiones.

¿Quiénes son y cómo compran? (exploración)

Tabla 1: Decisiones de limpieza y construcción de variables (antes → después).

Paso	Decisión	Detalle
Lectura	CSV crudo → datos	15 columnas tal como se reciben
Duplicados	Verificación	0 duplicados → sin acción
Perdidos	Verificación	0 perdidos → sin imputación
Extremos	Verificación	0 fuera de 1.5×IQR en las 10 numéricas → sin truncado
Categóricas	Recodificación	Gender y Promotion_Response a factor; Email_Opt_In y Target_Churn de texto «True/False» a lógico
Evento	Construcción	Target_Churn → evento (1 fuga, 0 retención): 526 fugas (52.6 %)
Tiempo	Construcción	Last_Purchase_Days_Ago → días de inactividad (1–364)
Satisfacción	Agrupación	Satisfaction_Score 1–2 → «Baja» (394); 3–5 → «Alta» (606)

El perfil del cliente es amplio y balanceado: edades de 18 a 69 años, ingresos anuales de 20 a 200 miles de dólares, antigüedad de 1 a 19 años y género repartido en tres tercios (Figura 1). El comportamiento de compra es igualmente disperso y sin valores extremos: de 1 a 99 compras al año, gasto total de 109 a 10,000 dólares y transacciones promedio de 10 a 500 dólares (Figura 2).

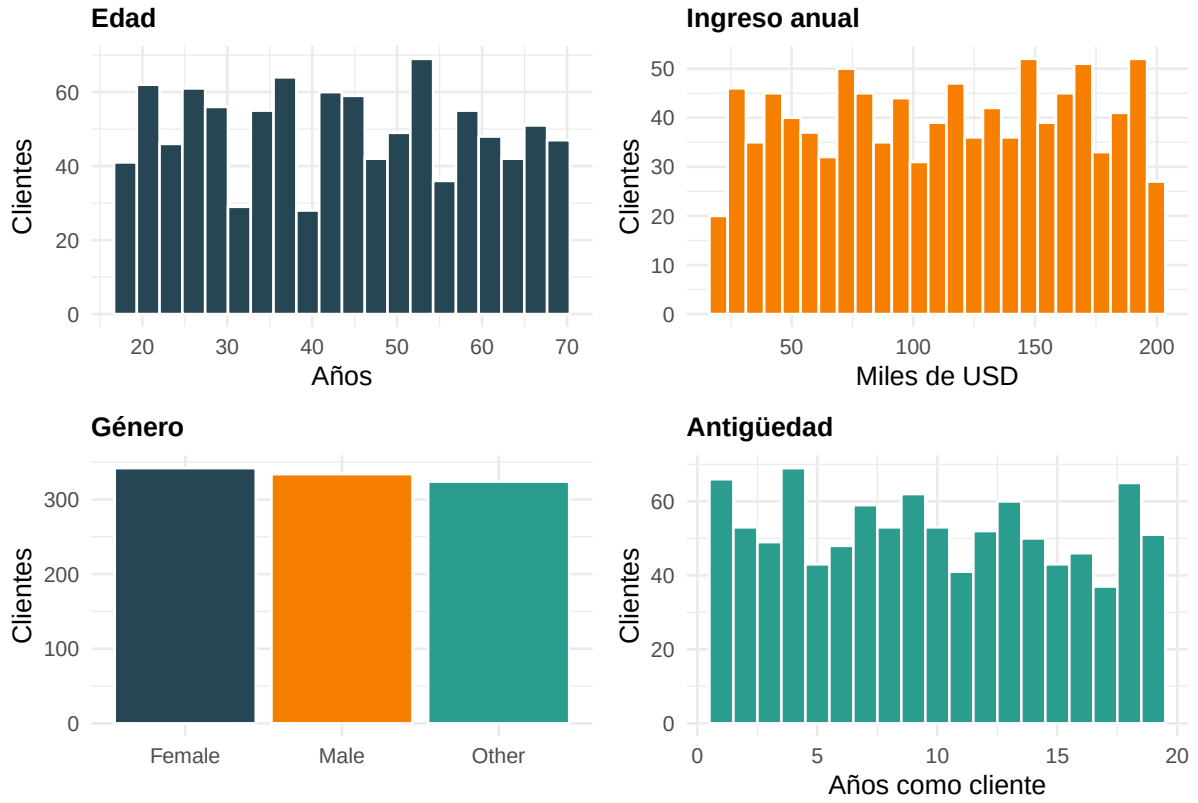


Figura 1: Perfil de los clientes: ninguna característica demográfica concentra a la base; el público es heterogéneo y balanceado.

Las variables numéricas entre sí prácticamente no se correlacionan (Figura 3): no existe un "cliente grande" (mucho ingreso y mucho gasto, muchas compras) ni combinaciones de variables que agrupen a la base. Esta primera señal — la base no tiene segmentos naturales — anticipa el hallazgo central del análisis de supervivencia.

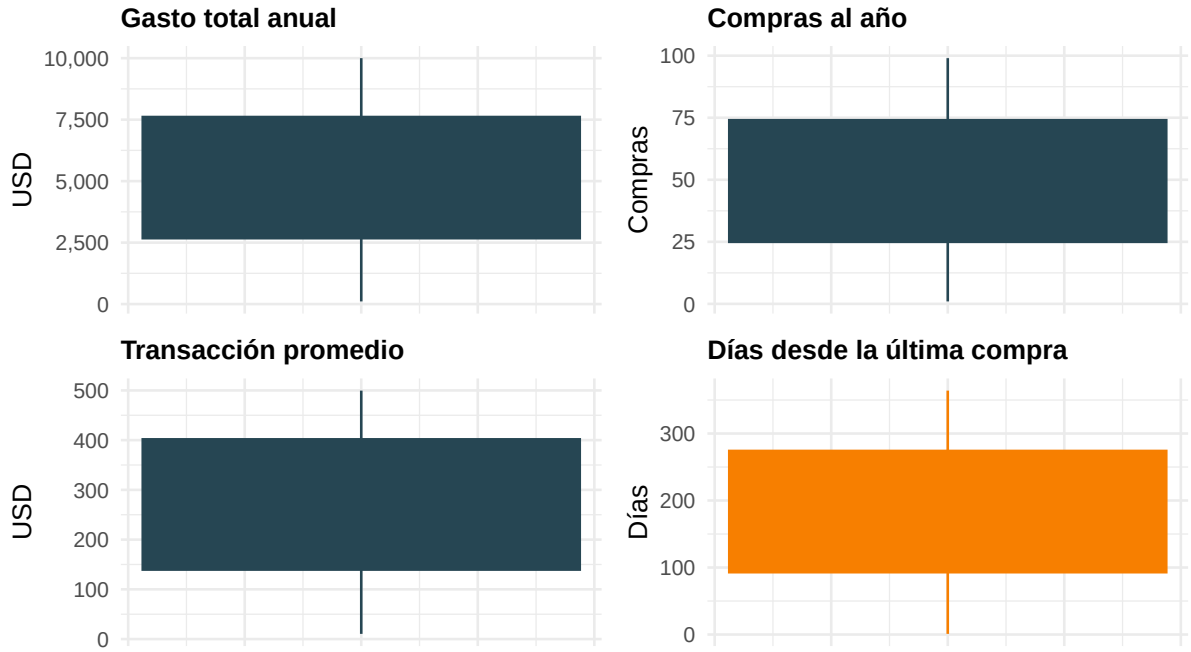


Figura 2: Diagramas de caja del comportamiento de compra: no hay valores extremos fuera de 1.5×IQR en ninguna variable; no se requirió truncado ni winsorización.

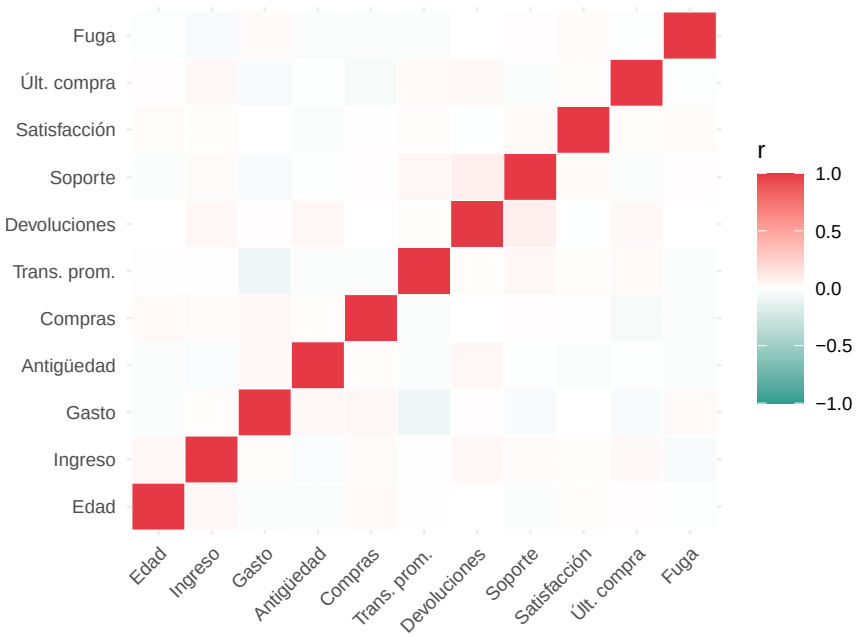


Figura 3: Correlaciones entre variables numéricas: todas cercanas a cero; la base no tiene segmentos naturales.

¿Qué distingue a quien fuga? (comparación inicial)

Al cruzar las variables de experiencia del cliente con el abandono (Figura 4: satisfacción, soporte y respuesta a promociones) no aparece ningún contraste: la distribución es la misma entre fugados y activos. La fracción de fuga oscila **sin tendencia entre 48.3 % y 60.8 %** en todas las ventanas del año.

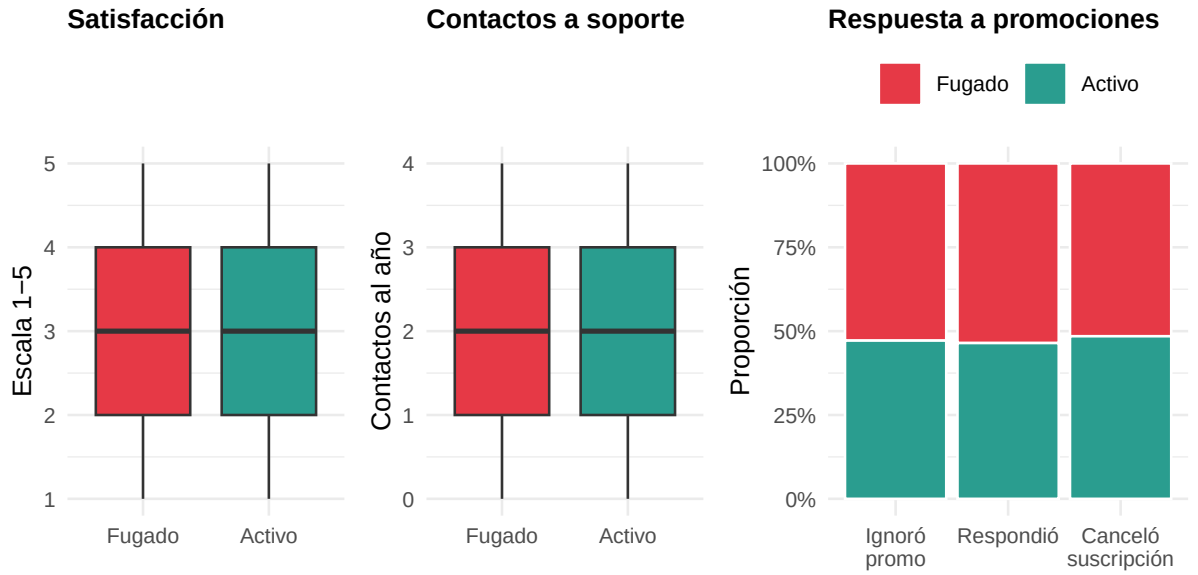


Figura 4: Fuga frente a satisfacción, soporte y promociones: las distribuciones de fugados (rojo) y activos (verde) son indistinguibles en toda variable.

¿Cuándo se van los clientes? (análisis de supervivencia)

La curva de Kaplan–Meier global (Figura 5) responde la primera pregunta: la fuga **no se concentra en ningún periodo**. El abandono se acumula a un ritmo promedio de 1.45 clientes por día: el riesgo es plano durante la mayor parte del año y se acelera al final, en la cola de la distribución de inactividad (Figura 5). La permanencia es del 94.9 % al día 30, 85.9 % al día 90 y 70.4 % al día 180; la mediana de "sobrevivencia" es de 269 días (IC 95 %: 255–283), es decir, la mitad de la base habría fugado hacia los 9 meses de inactividad. Parte de la aceleración final de la curva refleja el cierre de la ventana de observación (un cliente solo puede acumular hasta 364 días de inactividad) y no un cambio de comportamiento.

Las comparaciones por segmento (Figura 6) confirman la segunda pregunta. Para la satisfacción se prueba H0: la permanencia es igual entre clientes con satisfacción baja y alta, contra la alternativa de que difiere; las curvas de satisfacción baja (394 clientes) y alta (606) se traslapan (log-rank $p = 0.230$). La misma prueba entre quienes respondieron, ignoraron o cancelaron su suscripción a las promociones tampoco detecta diferencias ($p = 0.509$). Ninguna diferencia es estadísticamente detectable.

Para ponderar todas las variables a la vez, ajustamos el modelo de Cox, que estima cuánto multiplica cada característica el riesgo de fuga manteniendo el resto constante (Tabla 2). La lectura ejecutiva de la tabla: **ningún hazard ratio se aleja de 1.0 con confianza** — el intervalo de cada variable incluye al 1.0 — y la significancia más cercana (gasto total, $p = 0.054$) no alcanza el umbral convencional de 0.05. Para validar las estimaciones se prueba H0: los riesgos proporcionales se mantienen en el tiempo (supuesto del modelo); **no se detecta violación del supuesto** (prueba global $p = 0.77$), de modo que las estimaciones son válidas; lo que dicen es simplemente que no hay efectos.

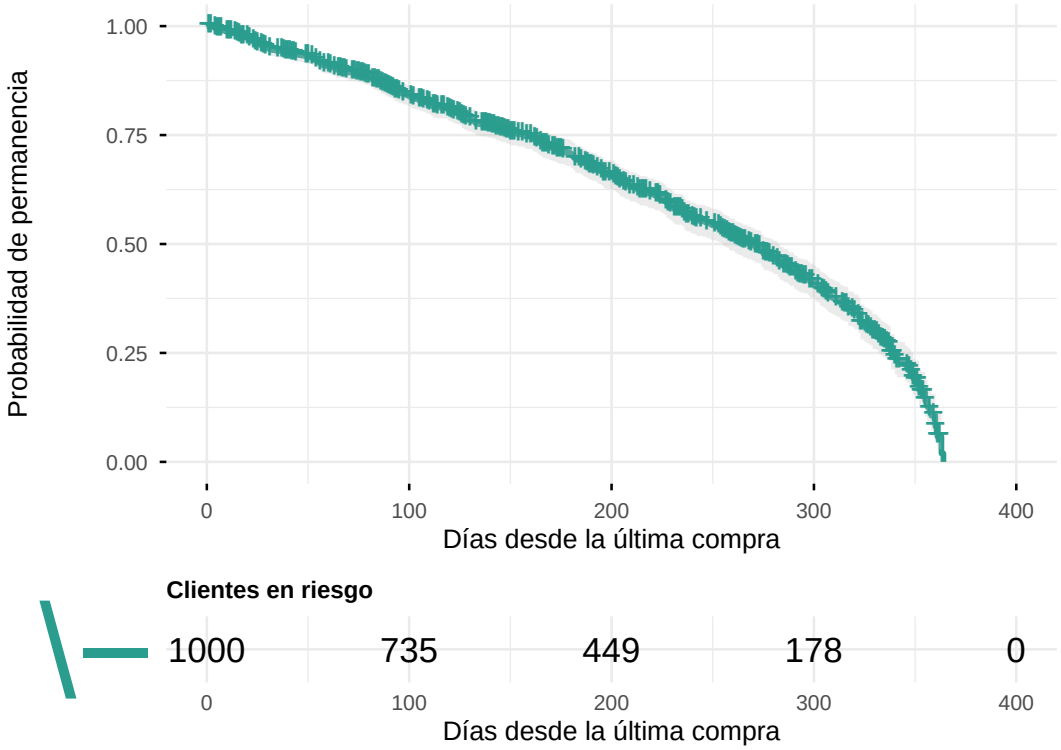


Figura 5: Kaplan–Meier global: la permanencia cae de manera pareja la mayor parte del año y se acelera al final (cola de inactividad); la mitad de la base habría fugado hacia el día 269. La acción de retención debe activarse antes del día 180.

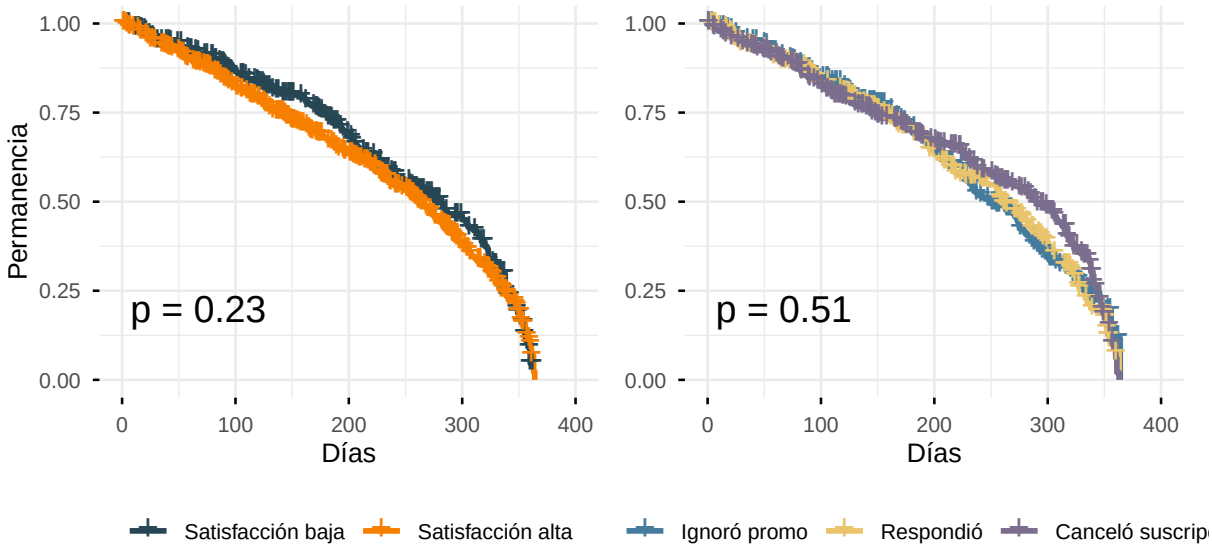


Figura 6: Permanencia según satisfacción y respuesta a promociones: las curvas se traslapan (log-rank p=0.23 y p=0.51); ningún segmento retiene mejor que otro.

Tabla 2: Modelo de Cox: hazard ratios (HR) por variable. HR > 1 aumenta el riesgo de fuga; ningún intervalo excluye al 1.0 (el de Gasto lo roza por arriba, p = 0.054) → ningún efecto detectable.

Variable	HR	IC	p
Edad	1.000	[0.994, 1.005]	0.933
Ingreso anual (miles USD)	0.998	[0.997, 1.000]	0.064
Gasto por cada 1,000 USD	1.031	[1.000, 1.064]	0.054
Antigüedad (años)	0.992	[0.977, 1.008]	0.323
Compras al año	1.000	[0.997, 1.003]	0.795
Transacción por cada 1,000 USD	0.709	[0.394, 1.276]	0.251
Devoluciones	0.987	[0.958, 1.017]	0.389
Contactos a soporte	1.031	[0.970, 1.096]	0.332
Satisfacción (1–5)	1.000	[0.940, 1.064]	0.997
Aceptó correos (sí vs no)	0.932	[0.784, 1.108]	0.425
Respondió promo (vs ignoró)	1.045	[0.842, 1.297]	0.691
Canceló promo (vs ignoró)	0.938	[0.757, 1.162]	0.557

Qué implica esto para el negocio

1. El riesgo es plano y alto: retener requiere actuar a todos, no a unos pocos. Con 52.6 % de fuga anual, sin segmentos distinguibles y con un riesgo que solo se acelera al final del año, un programa de retención dirigido a "clientes en riesgo" no tiene a dónde apuntar: las señales disponibles no anticipan nada. La modificación al producto que este análisis sostiene es un **ciclo de re-engagement universal**: contacto preventivo a toda la base antes del día 180 (cuando la permanencia sigue en 70.4 %) — por ejemplo, incentivo de recompra y recordatorio de valor. La cadencia de repetición (p. ej. trimestral) es una decisión de implementación que este análisis no puede fijar con estos datos.

2. Las promociones actuales no muestran efecto medible; no conviene escalarlas. Fugas y permanencia se comportan igual entre quienes respondieron y quienes cancelaron su suscripción a la campaña (p = 0.509; HR de 1.04, IC 95 % `[0.84, 1.30]`). Antes de invertir más en la campaña, hay que rediseñarla para que sea capaz de mover la retención.

3. Re-instrumentar el registro de clientes es la modificación de mayor valor a largo plazo. Este análisis se limita por cómo se capturó la información: no hay fecha de alta, ni historial de compras fechado, ni fecha de baja — solo un corte de "días desde la última compra" y una marca final de abandono. Registrar esas fechas convertiría el siguiente análisis en un seguimiento real del tiempo de vida del cliente, donde sí puedan detectarse segmentos de riesgo y medirse las campañas de retención.

Nota técnica (para quien domina el tema). Tiempo = `Last_Purchase_Days_Ago` (1–364 días), evento = `Target_Churn` (526 fugas en 1,000 clientes); censurados a la derecha sin fuga. Cox con todas las covariables de la Tabla 2: sin HR significativo; `cox.zph` global p = 0.77 (sin violación del supuesto de riesgos proporcionales). La base muestra patrones compatibles con datos simulados (varianzas planas, nulas correlaciones), por lo que las conclusiones de negocio son provisionales mientras la instrumentación no mejore.